



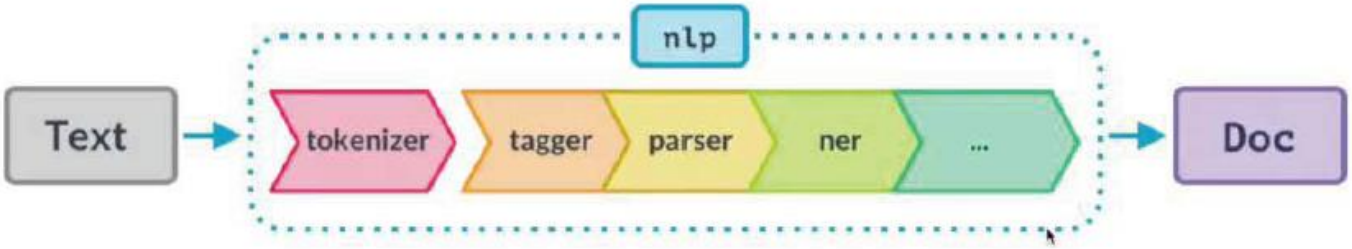
Processamento de Linguagem Natural com Deep Learning

Prof. Dr. Anselmo C. de Paiva paiva@nca.ufma.br
Núcleo de Computação Aplicada NCA - UFMA
Dep. De Informática - Universidade Federal do Maranhão

Processamento de Texto

Tarefas de Processamento de Texto

- Expressões regulares
- Normalização
  - Segmentação de texto (tokenização)
  - Stemização (Radicalização)
  - Lematização
- **Marcação de partes da fala (POS-Tagging)**
- **Reconhecimento de entidades nomeadas**
- Resolução de correferência



Rotulagem de Sequências
Sequence Labeling

- Based on slides from:
  - Alessandro Moschitti & Olga Uryupina Dep. of Inf. and Com. Tech. University of Trento
  - Sam Bowman, DS-GA 1012

Rotulagem de Sequências

- Objetivo:
  - classificar cada token (palavra) em um espaço de classes C
  - Classificação pode ser:
    - Independente: cada palavra é tratada de forma independente
    - Dependente: cada palavra depende de outras palavras

Rotulagem de Sequências

- Marcação de classes gramaticais (Pos Tagging)
  - Partes do discurso em uma frase com suas classes gramaticais (substantivos, verbos e adjetivos)
  - Ajuda mecanismo de busca a fornecer resultados mais relevantes.
- Reconhecimento de Entidades Nomeadas (NER)
  - Identifica e classifica entidades nomeadas em um texto (pessoas, organizações e locais)
  - Extrair informações de corpus de textos e ajudar a identificar mais rapidamente o que se deseja.
- Chunking
  - divisão de uma sequência de palavras em pedaços ou subsequências não sobrepostas
    - marcados com um rótulo que indica seu tipo ou função na sequência.
  - Etapa de pré-processamento para NER e Pos Tagging
- Rotulagem de função semântica
  - Significado e as relações entre as partes da fala.
- Localizacao de respostas (Question Answering)
  - Marca o trecho da resposta dentro do texto com tags tipo BIO, tratando a extracao de respostas como rotulagem de sequencia

Classe de Palavras

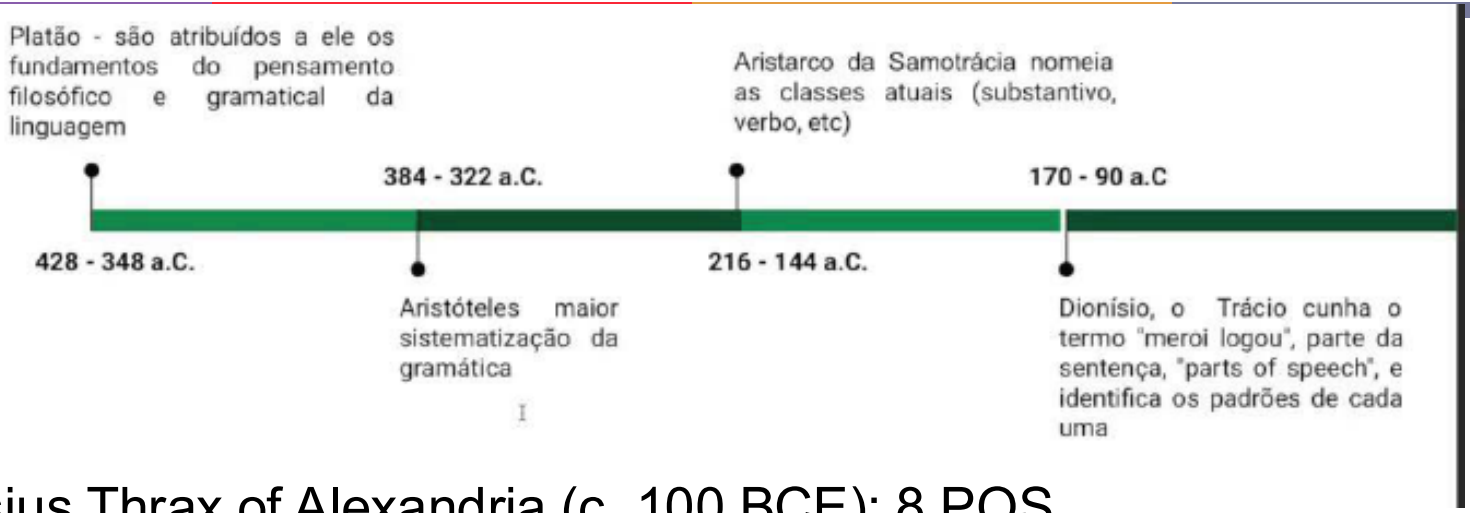
”Hal ... passe para controle manual de hibernação."

- Como definir a classe e função de "passe"?
  - Sem observar a sintaxe, pode ser:
    - Palavra nominal num grupo nominal
      - “0 passe do jogador”
    - Palavra verbal num grupo verbal realizando modo imperativo (comando)
      - "Passe para controle manual”
    - Palavra verbal num grupo verbal realizando modo subjuntivo (hipótese)
      - "Duvido que ele passe no teste"

Marcação de Classes Gramaticais

Part of Speech Tagging

Partes da Fala (POS) / Classes de Palavras



- Dionysius Thrax of Alexandria (c. 100 BCE): 8 POS
  - exatamente os que nos ensinam hoje
  - Thrax:
    - substantivo, verbo, artigo, advérbio, preposição, conjunção, particípio, pronome
  - Gramática escolar:
    - substantivo, verbo, adjetivo, advérbio, preposição, conjunção, pronome, interjeição

POS – Partes do Discurso - Classes Gramaticais



POS - Classes Gramaticais

- **1. Substantivo**
  - A **Ana** é super inteligente.
  - O **Brasil** é lindo.
  - A tua **beleza** me encanta.
- **2. Verbo**
  - **Sairemos** esta noite?
  - **Corro** todos os dias.
  - **Chovendo**, eu não vou.
- **3. Adjetivo**
  - A criança ficou **feliz**.
  - O artigo ficou **superinteressante**.
- **4. Pronome**
  - **Eu** aposto como ele vem.
  - **Contigo** vou até a Lua.
  - **Aquele** tipo não me sai da cabeça.
- **5. Artigo**
  - **O** menino saiu.
  - **As** meninas saíram.
  - **Uns** constroem, outros destroem.
  - **Uma** chance é o que preciso.
- **6. Numeral**
  - **Um** pastel, por favor!
  - **Primeiro** as damas.
  - **Dezenas** de pessoas estiveram presentes.
- **7. Preposição**
  - Entreguei a carta **a** ele.
  - As portas abrem **após** as 18h.
  - Isto é **para** você.
- **8. Conjunção**
  - Vou, **mas** não volto.
  - **Portanto**, não sei o que fazer.
  - Dançar **conforme** a dança.
- **9. Interjeição**
  - **Olá!** Sou a Maria.
  - **Viva!** Conseguimos ganhar o campeonato.
  - **Psiu!** Não faça barulho aqui.
- **10. Advérbio**
  - O melhor resultado foi o do atleta estrangeiro
  - Não acha que trouxe folhas demais?
  - O restaurante é ali.

Classes de Palavras

- Palavras de classe aberta
  - Palavras de conteúdo: Substantivos, verbos, adjetivos, advérbios
  - Mais interjeições: oh, ouch, uh-huh, yes, hello
  - Novos substantivos e verbos como iPhone ou debugar
- Palavras de classe fechada
  - Associação relativamente fixa
  - Palavras funcionais: palavras curtas e frequentes com função gramatical
    - Artigos: "o", "a", "os", "as", "um", "uma", "uns", "umas";
    - Pronomes: ela, ele eu, este", "esta", "estes", "meu", "minha";
    - Preposições: A, Ante, Após, Até, Com

Palavra de Classe Aberta

Classe de palavra	Descrição	Exemplo
Adjetivo	Modificadores de substantivos	Seu **grande** amigo chegaria hoje
Advérbio	Modificadores de verbos, adjetivos e outros advérbios de acordo com tempo, modo ou lugar.	Ele ia **sempre** aos mesmos lugares.
Substantivo	Denominação de pessoas, lugares, entidades, etc. Núcleo de um sintagma nominal	Plantou uma **árvore** enorme.
Verbo	Denominação de ações e processos. Núcle de um sintagma verbal	**Gostaria** de uma bebida.
Nome Próprio	Nomes de pessoas, locais, organizações, etc.	**Joana** plantou uma árvore.
Interjeição	Expressam saudações e diversos estados	**Opa!** Vamos para a aula. **Ai!** Essa doeu.

Palavra de Classe Fechada

Classe de palavra	Descrição	Exemplo
Preposição	Marca relações entre substantivos	O professor **de** português
Verbo Auxiliar	Constrói significados de tempo, voz, aspecto de verbos plenos	Ele **tinha** ido.
Conjunção	Conecta duas frases ou orações	Eu joguei bola **e** fui descansar.
Artigo	Marca as propriedades de um sintagma nominal	**O** amigo veio.
Pronome	Referência curta a uma pessoa, lugar, organização, entidade, etc.	**Ela** plantou uma árvore.

POS Corpus

- Anotação de classe de palavras para diferentes idiomas:
  - Inglês: Penn TreeBank
    - https://catalog.idc.uoenn.edu/LDC99T42
  - Português: Mac-Morpho
    - http://nilc.icmc.usp.br/macmorph
  - Multilingue: Universal Dependencies
    - http://universaldependencies.org
- Alguns corpora anotados com diferentes tagsets
  - conjuntos de classes (marcadores)

Tagset

- Especializações de 8 POS básicos
  - Substantivo, verbo, pronome, preposição, adjetivo, conjunção, artigo, advérbio
- Com base em semelhanças morfológicas e de distribuição
  - Não semântica.

- Vários conjuntos de tags padrão
- Escolha com base na aplicação
- Diferentes
  - Grau de granularidade
  - Decisões idiossincráticas

Penn Treebank não distingue to/Prep de to/Inf

I/PP want/VBP to/TO go/VB to/TO Zanzibar/NNP ./.

- Brown Corpus (Francis & Kucera '82), 1M words, 87 tags.

http://www.comp.leeds.ac.uk/amalgam/tagsets/brown.html

- Penn Treebank: Corpus do Wall Street Journal anotado a mão
  - 1M words, 45-46 tags

http://www.comp.leeds.ac.uk/amalgam/tagsets/upenn.html

- C5 tagset usado para o British National Corpus (BNC)

Tagset

- Exemplo Inglês:
  - Conjunto mais comum
  - Penn Treebank tagset (Marcus et al., 1993)

Tag	Description	Example	Tag	Description	Example
CC	coordin. conjunction	*and, but, or*	SYM	symbol	+,%, &
CD	cardinal number	*one, two*	TO	"to"	*to*
DT	determiner	*a, the*	UH	interjection	*ah, oops*
EX	existential 'there'	*there*	VB	verb base form	*eat*
FW	foreign word	*mea culpa*	VBD	verb past tense	*ate*
IN	preposition/sub-conj	*of, in, by*	VBG	verb gerund	*eating*
JJ	adjective	*yellow*	VBN	verb past participle	*eaten*
JJR	adj., comparative	*bigger*	VBP	verb non-3sg pres	*eat*
JJS	adj., superlative	*wildest*	VBZ	verb 3sg pres	*eats*
LS	list item marker	*1, 2, One*	WDT	wh-determiner	*which, that*
MD	modal	*can, should*	WP	wh-pronoun	*what, who*
NN	noun, sing. or mass	*llama*	WP$	possessive wh-	*whose*
NNS	noun, plural	*llamas*	WRB	wh-adverb	*how, where*
NNP	proper noun, sing.	*IBM*	$	dollar sign	$
NNPS	proper noun, plural	*Carolinas*	#	pound sign	#
PDT	predeterminer	*all, both*	"	left quote	' or "
POS	possessive ending	*'s*	"	right quote	' or "
PRP	personal pronoun	*I, you, he*	(	left parenthesis	[, (, {, <
PRP$	possessive pronoun	*your, one's*	)	right parenthesis	],), }, >
RB	adverb	*quickly, never*	,	comma	,
RBR	adverb, comparative	*faster*	.	sentence-final punc	. ! ?
RBS	adverb, superlative	*fastest*	:	mid-sentence punc	: ; ... – -
RP	particle	*up, off*			

Figure 10.1 Penn Treebank part-of-speech tags (including punctuation).

Tagset

- Português
  - https://www.sketchengine.eu/portuguese-freeling-part-of-speech-tagset/
- Universal POS tagset
  - Padrão para marcação multilíngue
    - https://universaldependencies.org/u/pos/
  - Inventário universal de categorias e diretrizes para facilitar a anotação de construções semelhantes em vários idiomas e o desenvolvimento de anotadores automáticos multilíngues.
  - Esquema de anotação baseado em:
    - Evolução das Dependências de Stanford (de Marneffe et al., 2006, 2008, 2014)
    - Etiquetas universais de parte da fala propostas em (Petrov et al., 2012)
    - Interseção de interlíngua para conjuntos de etiquetas morfossintáticas (Zeman, 2008)
  - A versão 2 tem 17 etiquetas de parte da fala (classes de fala)
    - A única etiqueta não usada pelo português brasileiro é uma partícula (PART).

Universal POS tagset

Nivre et al. 2016

	Tag	Description	Example
Open Class	**ADJ**	Adjective: noun modifiers describing properties	*red*, *young*, *awesome*
	ADV	Adverb: verb modifiers of time, place, manner	*very*, *slowly*, *home*, *yesterday*
	NOUN	words for persons, places, things, etc.	*algorithm*, *cat*, *mango*, *beauty*
	VERB	words for actions and processes	*draw*, *provide*, *go*
	PROPN	Proper noun: name of a person, organization, place, etc..	*Regina*, *IBM*, *Colorado*
	INTJ	Interjection: exclamation, greeting, yes/no response, etc.	*oh*, *um*, *yes*, *hello*
Closed Class Words	**ADP**	Adposition (Preposition/Postposition): marks a noun's spacial, temporal, or other relation	*in, on, by under*
	AUX	Auxiliary: helping verb marking tense, aspect, mood, etc.,	*can, may, should, are*
	CCONJ	Coordinating Conjunction: joins two phrases/clauses	*and*, *or*, *but*
	DET	Determiner: marks noun phrase properties	*a, an, the, this*
	NUM	Numeral	*one, two, first, second*
	PART	Particle: a preposition-like form used together with a verb	*up, down, on, off, in, out, at, by*
	PRON	Pronoun: a shorthand for referring to an entity or event	*she, who, I, others*
	SCONJ	Subordinating Conjunction: joins a main clause with a subordinate clause such as a sentential complement	*that*, *which*
Other	**PUNCT**	Punctuation	; , ()
	SYM	Symbols like $ or emoji	$, %
	X	Other	asdf, qwfg

Mac-Morpho tagset

Aluisio, S. et all, 2003

Table 1. Regular tags

Tag	Definition
ADJ	open-class noun modifier
ADV-KS-REL	relative subordinating Adverb
ADV-KS	Non-relative subordinating Adverb
ADV	Non-subordinating adverb
ART	Article
KC	coordinating conjunction
KS	coordinating conjunction
IN	interjection
N	open-class noun phrase nucleus
NPROP	proper noun
NUM	numeral as a noun modifier
PCP	past participle or adjective
PDEN	emphasis/focus
PREP	preposition
PROPESS	personal pronoun
PRO-KS-REL	relative subordinating pronoun
PRO-KS	Non-relative subordinating pronoun
PROSUB	non-subordinating pronoun as a noun phrase nucleus
PROADJ	Non-subordinating pronoun as a modifier
VAUX	Auxiliary verb
V	Non-auxiliary verb
CUR	Currency symbol

Table 2. Complementary tags

Compl. Tag	Definition
|EST	foreign
|AP	apposition
|+	contraction/ enclitic
|!	mesoclitic
| [beginning, |... middle part, |] and end of discontinuous compound (further discussed in Section 3)	
|TEL |DAT |HOR |DAD	phone number date time formatted data not falling into above categories

Pos Tagging



- Atribuir uma tag de parte da fala a cada palavra.
- Entrada:
  - Sequência de palavras (tokens) x1;x2; . . .;xn
  - Conjunto de tags
- Saída:
  - sequência de tags y1;y2; . . .;yn
  - Cada saída yi corresponde exatamente a uma entrada xi

- Entrada: Plays well with others
- Ambiguidade: NNS/VBZ UH/JJ/NN/RB IN NNS
- Saída: Plays/VBZ well/RB with/IN others/NNS

Penn Treebank POS tags

POS Tagging

- Eu gosto de chocolate.
  - Eu [PRON] gosto [VERB] de [ADP] chocolate [NOUN] .
- O sol está brilhando hoje.
  - O [DET] sol [NOUN] está [AUX] brilhando [VERB] hoje [ADV] .
- Ela correu no parque.
  - Ela [PRON] correu [VERB] no [ADP] parque [NOUN] .
- O livro está em cima da mesa.
  - O [DET] livro [NOUN] está [AUX] em [ADP] cima [ADP] da [DET] mesa [NOUN] .
- O cachorro é brincalhão.
  - O [DET] cachorro [NOUN] é [AUX] brincalhão [ADJ] .

Porque Pos Tagging?

- Indicativo de sintaxe
  - Frase: "O menino rápido correu para casa"
  - O/DET menino/NOUN rápido/ADJ correu/VERB para/ADP casa/NOUN
    - Sequência DET+NOUN+ADJ+VERB -> estrutura sintática da oração
      - Sujeito é um sintagma nominal (DET+NOUN+ADJ)
      - Predicado começa em VERB.
  - Tag de cada palavra indica sua função na frase e prevê que tipo de palavra pode aparecer em seguida.

Porque Pos Tagging?

- Indicativo de pronúncia
  - Frase 1: "Vou colher os frutos no pomar"
    - colher/VERB, sílaba tônica em "lher" (co.LHER)
  - Frase 2: "Preciso lavar a colher de sopa"
    - colher/NOUN, sílaba tônica em "co" (CO.lher)
  - mesma palavra (mesma grafia)
    - muda de classe gramatical, de VERB para NOUN
    - corresponde diretamente a uma mudança na sílaba tônica.
  - Sem a informação de POS, um sistema de conversão texto para fala não saberia se deve pronunciar "colher" com o acento em "lher" ou em "co"

Porque Pos Tagging?

- Indicativo de Expressão Multi Palavra
  - (MWE, expressão idiomática): "Ele é um cara de pau"
    - Ele/PRON é/VERB um/DET cara de pau/ADJ
      - "cara de pau" é tratado como uma única unidade lexical com tag ADJ
      - Funciona como adjetivo e significa "sem-vergonha" ou "descarado"
  - (uso literal, composicional): "A estátua indígena tem cara de pau"
    - A/DET estátua/NOUN indígena/ADJ tem/VERB cara/NOUN de/ADP pau/NOUN
      - três palavras recebem tags individuais,
      - leitura totalmente composicional, em que a estátua realmente tem um rosto feito de madeira.

POS Tagging é difícil?

- ~11% dos tipos de palavras no corpus Brown têm POS ambíguo
  - tendem a ser palavras muito comuns. E.g. that
    - I know *that* he is honest = IN
    - Yes, *that* play was nice = DT
    - You can't go *that* far = RB
- 40% dos tokens de palavras são ambíguos
  - Difícil até para as pessoas
    - Mrs/NNP Shaefer/NNP never/RB got/VBD around/RP to/TO joining/VBG
    - All/DT we/PRP gotta/VBN do/VB is/VBZ go/VB around/IN the/DT corner/NN
    - Chateau/NNP Petrus/NNP costs/VBZ around/RB 250/CD

POS Tagging, Outro Exemplo de Ambiguidade

- Manchetes de jornal são um caso clássico de ambiguidade sintática múltipla
  - “Fed raises interest rates 0.5 percent” admite varias leituras plausiveis de POS
  - NNP VBZ NN NNS CD NN, o Fed aumenta as taxas de juros em 0,5%
  - VBN VB NN NNS CD NN, leitura alternativa tratando “raises” como outro papel sintático
- Escolha correta depende da identidade da palavra e do contexto
  - Maioria das palavras tem no máximo duas tags possíveis, e o contexto vizinho resolve a ambiguidade na maior parte dos casos

Distribuição das Tags

- POS seguem o comportamento distributivo usual baseado em frequência
- Maioria dos tipos de palavras tem apenas uma classe gramatical
  - 85-86% não são ambíguas
- Palavras ambíguas (14-15%) são muito comuns
  - 55-67% dos tokens de palavras
  - A maioria tem duas
  - Um pequeno número de tipos de palavras tem muitas classes gramaticais
- Palavras que ocorrem com mais frequência tendem a ter várias tags

Tokens	Mac-Morpho	UD_Portuguese-GSD
Não Ambíguo	48.092 (**89%**)	27.074 (**88%**)
Ambíguo	6.143 (**11%**)	3.680 (**12%**)

Distribuição de Tags – Brown

- 11,5% das palavras em inglês no corpus Brown são ambíguas
- 40% dos tokens no corpus Brown são ambíguos

Unambiguous	(1 tag)	35,340	
Ambiguous	(2-7 tags)	4,100	
	2 tags	3,760	
	3 tags	264	
	4 tags	61	
	5 tags	12	
	6 tags	2	
	7 tags	1	(“still”)

Fontes de Informação para POS tagging

- Conhecimento de palavras vizinhas
  - Bill saw that man yesterday
  - NNP NN DT NN NN
  - VB VB(D) IN VB NN
- Conhecimento das probabilidades de palavras
  - man raramente é usado como um verbo....

Abordagens para POS Tagging

- Baseada em regras
  - conjuntos de regras criadas manualmente para marcar frases de entrada
  - Por exemplo, uma palavra antecedida por um artigo é um substantivo
- Estatísticas
  - Corpus para calcular a probabilidade de uma tag em um contexto
  - Classe mais provável de uma palavra em função das palavras vizinhas
- Aprendizado de máquina
  - Dados anotados manualmente disponíveis
  - Aprende a identificar padrões das classes gramaticais
- Hibridismo também é possível
  - Por exemplo, aprendizado de regras a partir de corpus

Abordagem baseada em regras

- Exemplo de dados pós-morfológicos (Penn tagset):

I	watch	a	fly	.
NN	NN	DT	NN	.
PRP	VB	NN	VB	
	VBP		VBP	

- Regras
  - formas de palavras, do contexto e da posição atual
  - tags, a partir do contexto e da posição atual
  - conjuntos de tags, do contexto e da posição atual
  - combinações dos mesmos

Exemplo de Regras

- Tipo If-then:
  - $DT_{eq,-1,Tag}$ => NN
    - (implies $NN_{in,0,Set}$ as a condition)
  - $PRP_{eq,-1,Tag}$ and $DT_{eq,+1,Tag}$ => VBP
  - $\{DT,NN\}_{sub,0,Set}$ => DT
  - $\{VB,VBZ,VBP,VBD,VBG\}_{inc,+1,Tag}$ => not DT
- Expressõe Regulares:
  - not(<*,*,DT> <*,*,notNN>))
  - not(<*,*,PRP>,<*,*,notVBP>,<*,*,DT>)
  - not(<*,$\{DT,NN\}_{sub}$,notDT>)
  - not(<*,*,DT>,<*,*,{VB,VBZ,VBP,VBD,VBG}>)

I	watch	a	fly	.
NN	NN	DT	NN	.
PRP	VB	NN	VB	
	VBP		VBP	

Métodos Estatísticos

- HMM
  - A tag anterior e a palavra atual devem influenciar a tag atual
- Entropia máxima
  - Marcador baseado em recursos
- Etiqueta mais frequente: Linha de base
  - Atribuir a tag mais frequente para cada palavra com base no treinamento.

Cadeias de Markov

- Cadeia de Markov
  - Atribui uma probabilidade a uma sequência de eventos observáveis
- Estados
  - valores que a variável pode assumir a cada momento
  - por exemplo o tempo, quente, frio ou ameno
- Transições
  - probabilidade de passar de um estado para outro
  - representadas como arestas em um grafo
- Hipótese de Markov
  - próximo estado depende apenas do estado atual, e não de todo o histórico anterior
  - $P(q_i \mid q_1, \ldots, q_{i-1}) = P(q_i \mid q_{i-1})$

Modelo Oculto de Markov, HMM

- POS Tagging
  - classes gramaticais não são observadas diretamente, apenas as palavras
  - tags são consideradas ocultas (inferidas a partir da sequência de palavras)
- HMM, Hidden Markov Model
  - Q, um conjunto de N estados, correspondendo às tags possíveis
  - A, a matriz de transição
    - a_{ij} é a probabilidade de passar do estado i para o estado j
  - B, probabilidades de emissão
    - probabilidade de uma palavra ser gerada por um estado
  - π, a distribuição inicial de probabilidade sobre os estados
- Duas hipóteses simplificadoras tornam o modelo tratável
  - Hipótese de Markov, a tag atual depende apenas da tag anterior
  - Independência das observações, palavra depende apenas de sua própria tag

HMM Tagging como Decodificação

- Decodificação, encontrar a sequência de estados mais provável dada uma sequência de observações
- Objetivo, escolher a sequência de tags t1...tn mais provável dada a sequência de palavras w1...wn
  - $\hat{t} = \text{argmax } P(t_1...t_n \mid w_1...w_n)$
- Aplicando a regra de Bayes e descartando o denominador, constante para uma dada frase
  - $\hat{t} = \text{argmax } P(w_1...w_n \mid t_1...t_n) \cdot P(t_1...t_n)$
- Com as duas hipóteses simplificadoras do HMM, a equação se reduz a um produtório
  - $\hat{t} \approx \text{argmax de } \Pi_i P(w_i \mid t_i) \cdot P(t_i \mid t_{i-1})$
  - primeiro termo é a probabilidade de emissão
  - segundo é a probabilidade de transição

O Algoritmo de Viterbi

- Resolve um problema de HMM (Hidden Markov Model):
- Dada uma sequência de palavras $o_1, o_2, \ldots, o_T$, encontrar a sequência de estados (tags) $t_1, t_2, \ldots, t_T$ que maximiza a probabilidade conjunta

$$P(t_1, \ldots, t_T \mid o_1, \ldots, o_T) \approx \prod_{i=1}^{T} [P(t_i \mid t_{i-1}) \cdot b(o_i \mid t_i)]$$

- Duas suposições de Markov simplificam o cálculo
  - Probabilidade de uma tag depende apenas da tag anterior (matriz A)
  - Probabilidade de uma palavra depende apenas da tag atual (matriz B).
- Passo de recorrência, para cada estado s no tempo t
  - viterbi[s,t] = máximo sobre s' de viterbi[s',t−1] × a(s',s) × b(s, ot)

Estimando as Probabilidades

- Contagem de frequência em um corpus anotado,
  - E.g. WSJ, Wall Street Journal
- Probabilidade de transição (Matriz A)

$$a(s', s) = P(t_i = s \mid t_{i-1} = s') \approx \frac{C(t_{i-1} = s', t_i = s)}{C(t_{i-1} = s')}$$

  - verbos modais (will) costumam ser seguidos por verbo no infinitivo, VB
    - Corpus WSJ: MD ocorre 13124 vezes, seguido de VB em 10471 delas,
    - P(VB | MD) = 0,80
  - Conta quantas vezes a tag s apareceu logo depois da tag s'
    - divide pelo número total de vezes que s'apareceu.
  - $a(\langle s \rangle, s)$ é a probabilidade de a frase começar com a tag s.

Exemplo, Matriz de Transição A

- Probabilidades de transição (corpus WSJ, Marcus et al. 1993)

anterior \ atual	NNP	MD	VB	DT	NN
<s>	0,2767	0,0006	0,0031	0,2026	0,0449
NNP	0,3777	0,0110	0,0009	0,0025	0,0584
MD	0,0008	0,0002	0,7968	0,0041	0,0008
VB	0,0322	0,0005	0,0050	0,2231	0,0615
DT	0,1147	0,0021	0,0002	0,0017	0,4744
NN	0,0096	0,0176	0,0014	0,0068	0,1216

Estimando as Probabilidades

- Contagem de frequência em um corpus anotado,
  - E.g. WSJ, Wall Street Journal
- Probabilidade de emissão (matriz B)

$$b(s,o) = P(w_i = o \mid t_i = s) \approx \frac{C(t_i{=}s, w_i{=}o)}{C(t_i{=}s)}$$

  - 13124 ocorrências de MD no corpus, 4046 correspondem à palavra will,
    - P(will|MD) = 0,31
    - P(will | MD) não responde qual é a tag mais provável de will
      - se eu fosse gerar um MD, qual a chance de ser will
  - chance de a palavra o ser emitida quando o estado é a tag s.
  - Contando pares (tag, palavra):

Exemplo, Matriz de Emissão B e Resultado

- Probabilidades de emissão, recorte do corpus WSJ

tag \ palavra	Janet	will	back	the	bill
NNP	0,000032	0	0	0,000048	0
MD	0	0,308431	0	0	0
VB	0	0,000028	0,000672	0	0,000028
DT	0	0	0	0,506099	0
NN	0	0,000200	0,000223	0	0,002337

Recorrência do Viterbi

- Sejam N o número de tags possíveis e T o número de palavras da frase.
- **Matriz de probabilidades** $v_t(s)$
  - valor do melhor caminho até o estado s no tempo t:
    - $v_t(s) = \max_{s' \in S} [v_{t-1}(s') \cdot a(s', s)] \cdot b(s, o_t)$
- **Matriz de ponteiros** $bp_t(s)$
  - indicando qual estado anterior gerou o melhor caminho:
    - $bp_t(s) = \arg\max_{s' \in S} [v_{t-1}(s') \cdot a(s', s)]$
- Caso base ($t = 1$):
  - $v_1(s) = a(\langle s \rangle, s) \cdot b(s, o_1)$
- Probabilidade da melhor sequência é
  - $\max_s v_T(s)$
- Sequência de tags é recuperada seguindo os ponteiros bp de trás para frente.

Recorrência do Viterbi

- Passo de recorrência, para cada estado s no tempo t
  - $v(t, s) = \max_{s'} [\, v(t\text{-}1, s') \cdot a(s', s) \,] \cdot b(s, o_t)$
  - $bp(t, s) = \operatorname{argmax}_{s'} [\, v(t\text{-}1, s') \cdot a(s', s) \,]$
- Para cada estado s,
  - testa todos os estados anteriores s’
  - mantém apenas o melhor caminho até ali
  - v(t, s) guarda o valor de probabilidade do melhor caminho;
  - bp(t, s) guarda de qual estado s' ele veio
- Custo total fica proporcional a $N^2 \times T$
  - em vez de testar todas as N^T combinações possíveis

Exemplo

- Estados possíveis
  - $S = \{\text{NNP, MD, VB, DT, NN}\}$
- $o =$ (Janet, will, back, the, bill)
- $T = 5$
- **t = 1, palavra "Janet"**
  - $v_1(s) = a(\langle s \rangle, s) \cdot b(s, \text{Janet})$
- Só NNP sobrevive
  - "Janet" só tem emissão diferente de zero como NNP.

s	$a(\langle s \rangle, s)$	$b(s, \text{Janet})$	$v_1(s)$
NNP	0,2767	0,000032	$\mathbf{8{,}8544 \times 10^{-6}}$
MD	0,0006	0	0
VB	0,0031	0	0
DT	0,2026	0	0
NN	0,0449	0	0

Recorrência instanciada, passo a passo (1/2)

Em cada passo, apenas o termo s' que venceu o máximo é mostrado

t1, Janet, caso base

$$v(1, \text{NNP}) = a(\langle s \rangle, \text{NNP}) \cdot b(\text{NNP}, \text{Janet}) = 0{,}2767 \times 0{,}000032 = \mathbf{8{,}8544 \times 10^{-6}}$$

t2, will, tag vencedora MD, veio de NNP

$$v(2, \text{MD}) = v(1, \text{NNP}) \cdot a(\text{NNP}, \text{MD}) \cdot b(\text{MD}, \text{will})$$

$$8{,}8544 \times 10^{-6} \times 0{,}0110 \times 0{,}308431 = \mathbf{3{,}004 \times 10^{-8}}$$

t3, back, tag vencedora VB, veio de MD

$$v(3, \text{VB}) = v(2, \text{MD}) \cdot a(\text{MD}, \text{VB}) \cdot b(\text{VB}, \text{back})$$

$$3{,}004 \times 10^{-8} \times 0{,}7968 \times 0{,}000672 = \mathbf{1{,}609 \times 10^{-11}}$$

Recorrência instanciada, passo a passo (2/2)

t4, the, tag vencedora DT, veio de VB

$$v(4, DT) = v(3, VB) \cdot a(VB, DT) \cdot b(DT, the)$$

$$1{,}609 \times 10^{-11} \times 0{,}2231 \times 0{,}506099 = \mathbf{1{,}816 \times 10^{-12}}$$

t5, bill, tag vencedora NN, veio de DT

$$v(5, NN) = v(4, DT) \cdot a(DT, NN) \cdot b(NN, bill)$$

$$1{,}816 \times 10^{-12} \times 0{,}4744 \times 0{,}002337 = \mathbf{2{,}013 \times 10^{-15}}$$

Passo	Termo vencedor	Valor de v
t1, Janet	início → NNP	$8{,}8544 \times 10^{-6}$
t2, will	NNP → MD	$3{,}004 \times 10^{-8}$
t3, back	MD → VB	$1{,}609 \times 10^{-11}$
t4, the	VB → DT	$1{,}816 \times 10^{-12}$
t5, bill	DT → NN	$2{,}013 \times 10^{-15}$

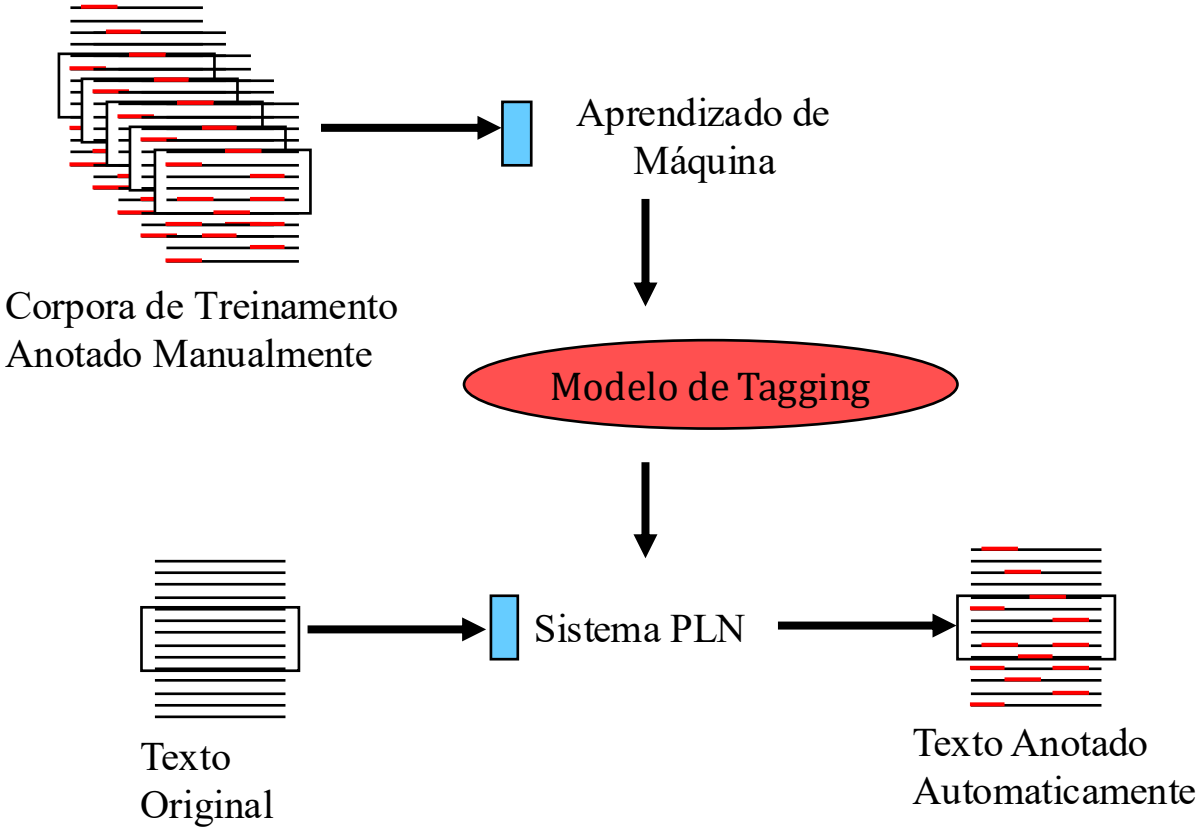
Engenharia de Atributos para POS Tagging

- Tratar POS tagging como classificacao independente por token
  - escolha dos atributos (features) determina a qualidade do resultado
- Linha de base: classe mais frequente
  - acuracia de 0,38
- Usar os primeiros e ultimos caracteres da palavra (un-, re-, -ly, -ing) como atributos
  - acuracia sobe para 0,55
- Incorporar conhecimento externo (WordNet) para caracterizar a palavra
  - acuracia sobe para 0,82
- Erros se concentram em palavras funcionais frequentes e ambíguas
  - como back, then, now, there
- Classificar cada palavra de forma independente ignora a dependencia entre tags vizinhas
  - substantivo tende a ser precedido por um adjetivo
- Essa limitacao motiva os modelos conjuntos de sequencia, HMM e CRF

Engenharia de Atributos para POS Tagging

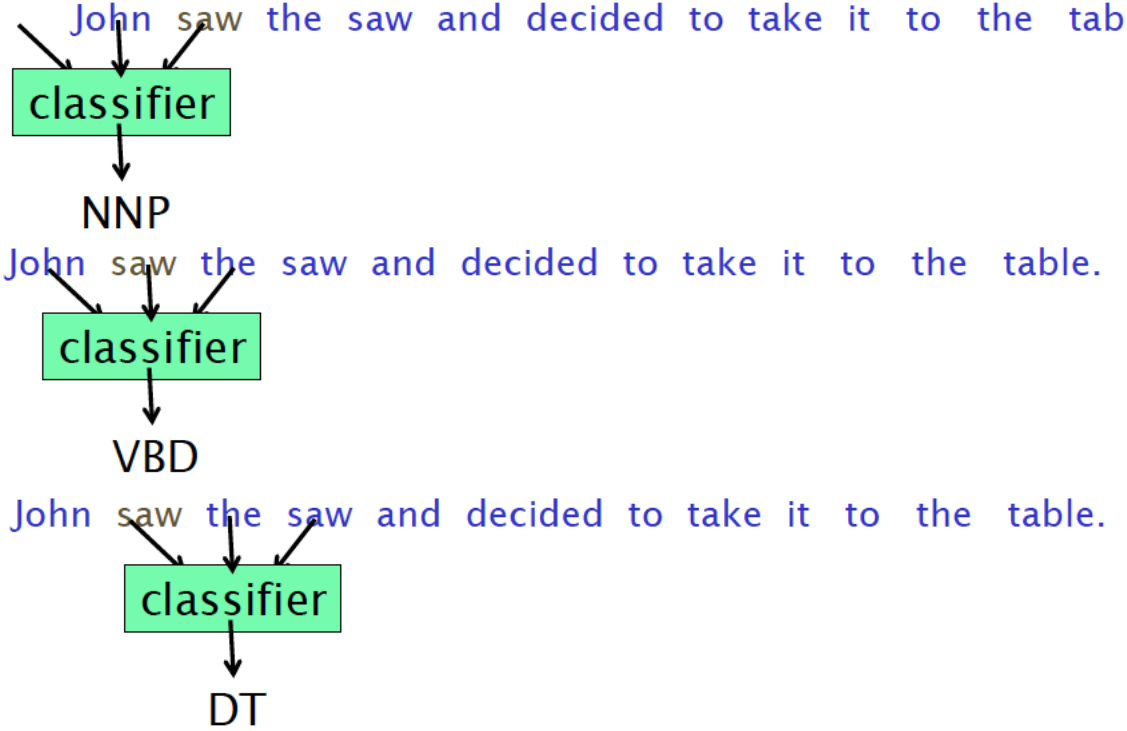
- POS tagging como classificação independente por token
  - escolha dos atributos (features) determina a qualidade do resultado
- Linha de base
  - prever sempre a classe mais frequente, acurácia de 0,38
- Prefixos e sufixos
  - usar os primeiros e últimos caracteres da palavra (un-, re-, -ly, -ing) como atributos,
  - acurácia sobe para 0,55
- Conhecimento externo (dicionario eletronico (WordNet))
  - acuracia sobe para 0,82
- Análise de erros mostra que os erros se concentram em palavras funcionais frequentes e ambiguas,
  - E.g. back, then, now, there
- Limitacao fundamental
  - Ignora a dependencia entre tags vizinhas
  - Substantivo tende a ser precedido por um adjetivo
  - determinante tende a ser seguido por substantivo ou adjetivo,
  - determinantes nao se repetem em sequencia
- Essa limitacao motiva os modelos conjuntos de sequencia, HMM e CRF

Abordagem de aprendizado

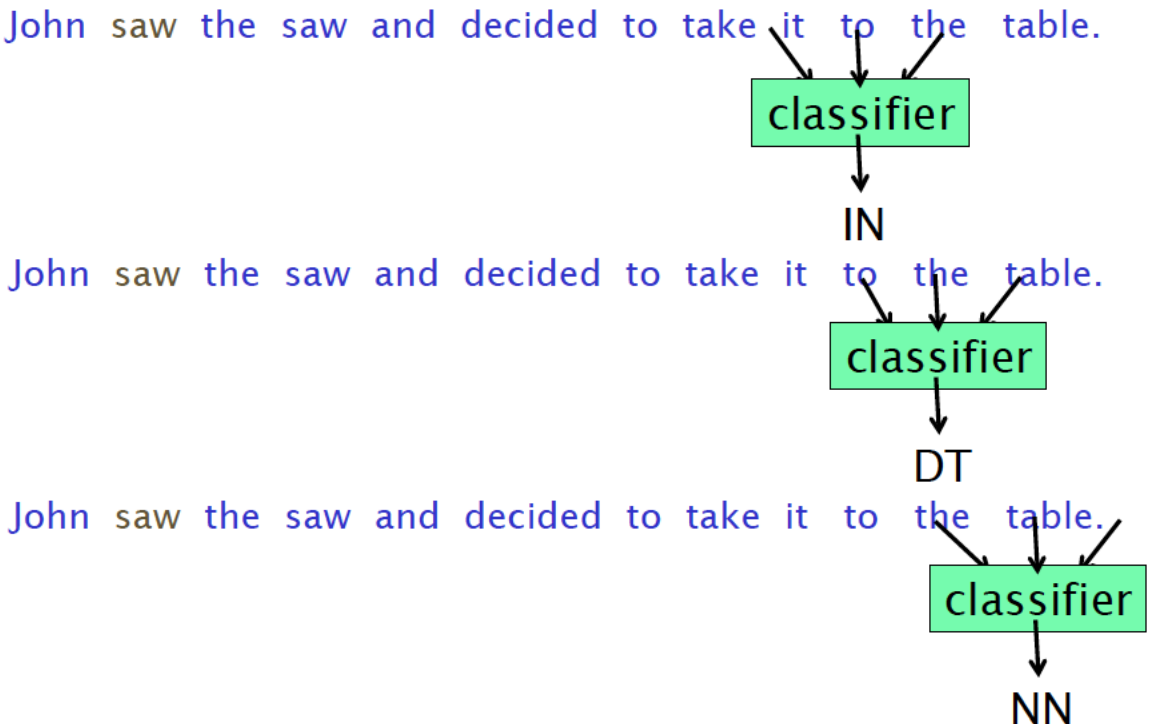


POS Taging como Classificação

- Classifica cada token de forma independente
- Usar informações sobre os tokens ao redor (janela deslizante).



POS Taging como Classificação



POS Tagging SOTA

Part-Of-Speech Tagging on Penn Treebank

Leaderboard Dataset



https://paperswithcode.com/sota/part-of-speech-tagging-on-penn-treebank

POS Tagging - Acurácia

- Acurácia :
  - Most frequent tag: ~90% / ~50%
  - Trigram HMM: ~95% / ~55%
  - Maxent P(t|w): 93.7% / 82.6%
  - TnT (HMM++): 96.2% / 86.0%
  - MEMM tagger: 96.9% / 86.9%
  - Bidirectional dependencies: 97.2% / 90.0%
  - Upper bound: ~98% (human agreement)
  - Concordancia entre anotadores humanos (Penn Treebank): ~96,5% (desacordo de 3,5%) *(Fonte: CMSC 470, UMD, Boyd-Graber)*

Most errors on unknown words

NLP Resources - Português

- https://github.com/inoueMashuu/POS-tagger-portuguese-nltk
- http://www.nilc.icmc.usp.br/nilc/tools/nilctaggers.html
- http://lxcenter.di.fc.ul.pt/tools/en/LXTaggerEN.html
- https://www.sketchengine.eu/portuguese-tagset/
- https://docs.huihoo.com/nltk/0.9.5/guides/portuguese_en.html
- https://forum.ailab.unb.br/t/datasets-em-portugues/251
- https://sites.icmc.usp.br/taspardo/Projects.htm
- https://inventory.clarin.gr/tool-service/780
- https://www.cis.lmu.de/~schmid/tools/TreeTagger/
- https://www.r-bloggers.com/2017/03/natural-language-processing-on-40-languages-with-the-ripple-down-rules-based-part-of-speech-tagger/

Reconhecimento de Entidades Nomeadas

Named Entity Recognition (NER)

Entidades Nomeadas

- Qualquer coisa a que se possa fazer referência com um nome próprio
  - PER (Pessoa): "Marie Curie". LOC (Local): "New York City" (Cidade de Nova York)
  - ORG (Organização): "Universidade de Stanford"
  - GPE (Entidade Geopolítica): "Boulder, Colorado"
- Também estendido a coisas que não são entidades:
  - datas, horários, preços

Type	Tag	Sample Categories	Example sentences
People	PER	people, characters	**Turing** is a giant of computer science.
Organization	ORG	companies, sports teams	The **IPCC** warned about the cyclone.
Location	LOC	regions, mountains, seas	The **Mt. Sanitas** loop is in **Sunshine Canyon**.
Geo-Political Entity	GPE	countries, states, provinces	**Palo Alto** is raising the fees for parking.
Facility	FAC	bridges, buildings, airports	Consider the **Golden Gate Bridge**.
Vehicles	VEH	planes, trains, automobiles	It was a classic **Ford Falcon**.

Figure 17.1 A list of generic named entity types with the kinds of entities they refer to.

Entidades Nomeadas

- Em geral
  - PERSON; ORGANIZATION; LOCATION
- Applications specific entity:
  - proteins, genes, commercial products, works of art.
  - GENIA corpus of MEDLINE abstracts (biomedical)

We have shown that [interleukin-1]$_{\text{PROTEIN}}$ ([IL-1]$_{\text{PROTEIN}}$) and [IL-2]$_{\text{PROTEIN}}$ control [IL-2 receptor alpha (IL-2R alpha) gene]$_{\text{DNA}}$ transcription in [CD4-CD8- murine T lymphocyte precursors]$_{\text{CELL LINE}}$

protein
cell line
cell type
DNA
RNA

Named Entity Recognition - NER

- Exemplo

Citing high fuel prices, [ORG **United Airlines**] said [TIME **Friday**] it has increased fares by [MONEY **$6**] per round trip on flights to some cities also served by lower-cost carriers. [ORG **American Airlines**], a unit of [ORG **AMR Corp.**], immediately matched the move, spokesman [PER **Tim Wagner**] said. [ORG **United**], a unit of [ORG **UAL Corp.**], said the increase took effect [TIME **Thursday**] and applies to most routes where it competes against discount carriers, such as [LOC **Chicago**] to [LOC **Dallas**] and [LOC **Denver**] to [LOC **San Francisco**].

Para que NER?

- Análise de sentimento
  - o sentimento do consumidor em relação a uma determinada empresa ou pessoa?
- Resposta a perguntas
  - responder a perguntas sobre uma entidade?
- Extração de informações
  - Extrair fatos sobre entidades do texto.

Complexidade do NER

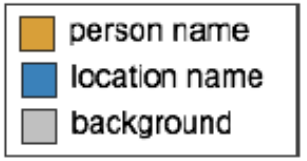
- Segmentação
  - POS Tagging
  - não segmentação, cada palavra recebe uma tag.
- NER precisa encontrar e segmentar as entidades!
  - Ambiguidade de tipo

[$_{PER}$ Washington] was born into slavery on the farm of James Burroughs.
[$_{ORG}$ Washington] went up 2 games to 1 in the four-game series.
Blair arrived in [$_{LOC}$ Washington] for what may well be his last state visit.
In June, [$_{GPE}$ Washington] passed a primary seatbelt law.

BIO Tagging (Ramshaw and Marcus, 1995)

- Abordagem padrão para rotulagem de sequência
  - problema de reconhecimento de intervalo
- Permite tratar NER como tarefa de rotulagem de sequência palavra por palavra
- Tags capturam tanto o limite quanto o tipo de entidade nomeada





BIO = Begin, Inside, Outside

BIO Tagging

- [PER Jane Villanueva] of [ORG United] , a unit of [ORG United Airlines Holding] , said the fare applies to the [LOC Chicago] route.

Words	BIO Label
Jane	B-PER
Villanueva	I-PER
of	O
United	B-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	B-LOC
route	O
.	O

Uma tag por token

- Representa
  - as mesmas informações que a anotação entre colchetes
  - tarefa como uma forma simples de modelagem de sequência
  - atribuir um único rótulo yi a cada palavra de entrada xi



tim cook is the ceo of apple

[tim cook]PER is the ceo of [apple]ORG

BIO Tagging

- B: token que inicia (*begins)* um intervalo
- I: tokens no interior (*inside)* do intervalo
- O: tokens fora(outside) do interval

- # de tags (n é #tipos de entidades):
- 1 O tag,
- *n* B tags,
- *n* I tags
- total de *2n+1*

Words	BIO Label
Jane	B-PER
Villanueva	I-PER
of	O
United	B-ORG
Airlines	I-ORG
Holding	I-ORG
discussed	O
the	O
Chicago	B-LOC
route	O
.	O

Variantes do BIO Tagging : IO e BIOES

- [PER Jane Villanueva] of [ORG United] , a unit of [ORG United Airlines Holding] , said the fare applies to the [LOC Chicago] route.

Words	IO Label	BIO Label	BIOES Label
Jane	I-PER	B-PER	B-PER
Villanueva	I-PER	I-PER	E-PER
of	O	O	O
United	I-ORG	B-ORG	B-ORG
Airlines	I-ORG	I-ORG	I-ORG
Holding	I-ORG	I-ORG	E-ORG
discussed	O	O	O
the	O	O	O
Chicago	I-LOC	B-LOC	S-LOC
route	O	O	O
.	O	O	O

Algoritmos para NER

- Aprendizado de Máquina Supervisionado
  - Hidden Markov Models
  - Conditional Random Fields (CRF)/ Maximum Entropy Markov Models (MEMM)
  - Neural sequence models (RNNs or Transformers)
  - Large Language Models (like BERT), finetuned

Por que ir além do HMM?

- HMMs têm dificuldade em incorporar características arbitrárias de forma direta
  - Maiúscula inicial, sufixos como -mente ou -ado, palavra anterior ou seguinte
- Palavras desconhecidas, nomes próprios, siglas e neologismos são um desafio recorrente
- CRF, Conditional Random Field
  - modelo discriminativo, baseado em modelos log-lineares, aplicado a sequências inteiras

Formalização do CRF

- Em vez de modelar P(X|Y) como o HMM, o CRF modela diretamente a probabilidade posterior P(Y|X)
- Cada característica local f_k depende da tag atual, da tag anterior, de toda a entrada X e da posição i
  - Templates de exemplo, $\langle y_i, x_i \rangle$, $\langle y_i, y_{i-1} \rangle$, $\langle y_i, x_{i-1}, x_{i+2} \rangle$
- Características locais são somadas ao longo de toda a frase, formando características globais Fk
  - $P(Y|X) = 1/Z(X) \times \exp \text{ de } \Sigma_k \, w_k \, F_k(X,Y)$
- Decodificação também usa o algoritmo de Viterbi
  - adaptado para somar os pesos das características em vez de multiplicar probabilidades

Características do CRF para NER

- Identidade da palavra atual e das palavras vizinhas
- Classe gramatical, POS, da palavra atual e das palavras vizinhas
- Prefixos e sufixos de até 4 caracteres
- Formato da palavra, word shape, letras minúsculas viram x, maiúsculas viram X, dígitos viram d
  - Exemplo, I.M.F. vira X.X.X. e DC10-30 vira XXdd-dd
- Gazetteer, presença da palavra em uma lista de nomes de lugares, pessoas ou organizações

Avaliação de POS Tagging e NER

- POS Tagging é avaliado pela acurácia, a proporção de tags corretas sobre o total de palavras
- NER é avaliado por precisão, recall e F1, pois envolve também um problema de segmentação
  - Precisão, proporção de entidades identificadas pelo sistema que estão corretas
  - Recall, proporção de entidades corretas que foram de fato identificadas
  - F1, média harmônica entre precisão e recall
- Em NER, a unidade de avaliação é a entidade inteira, não a palavra isolada
  - Rotular Jane mas não Jane Villanueva como pessoa conta como dois erros, um falso positivo e um falso negativo

Multi Word Expressions MWE

- Definição linguística
  - ”É uma combinação de palavras que deve ser tratada como uma unidade em algum nível de processamento linguístico". (Nicoletta Calzolari, 2002)
- Níveis:
  - Lexical: "ad hoc"
  - Sintático: "a princípio", "de repente"
  - Semântico: "primeiros socorros"
  - Pragmático/situacional: "good morning" (bom dia)
  - Estatístico: "salt and pepper" (sal e pimenta) (Kordoni e Egg, 2013)

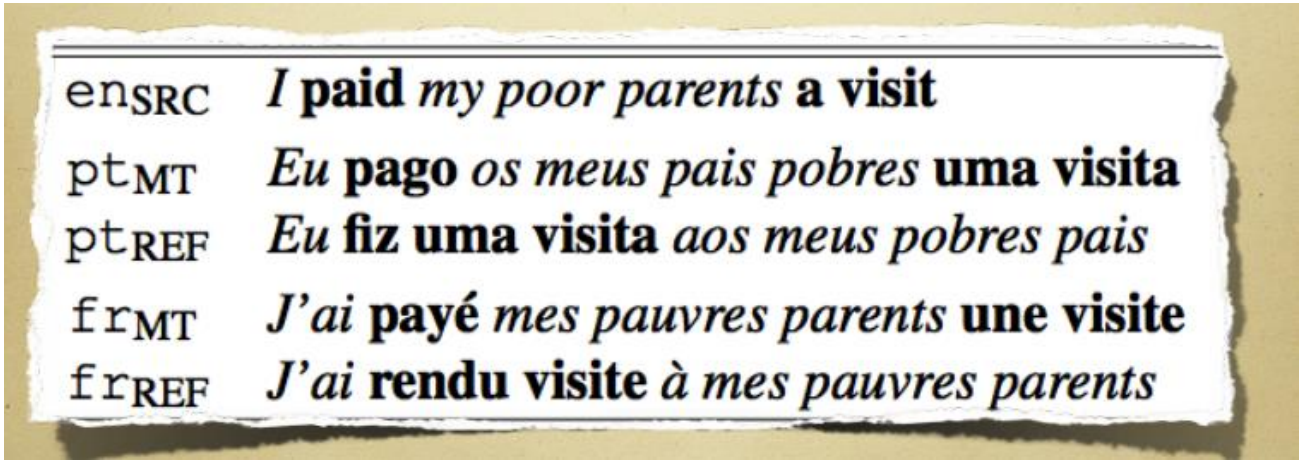
MWE - Exemplos

- De vez em quando: significa ocasionalmente, de tempos em tempos.
  - Exemplo: "Eu gosto de sair com os meus amigos de vez em quando."
- Mão na massa: significa colocar-se em ação, começar a trabalhar.
  - Exemplo: "Vamos colocar as mãos na massa e terminar esse projeto."
- Pé de moleque: um doce típico brasileiro feito com amendoim e rapadura.
  - Exemplo: "Vou comprar um pedaço de pé de moleque na feira.
- Cara de pau: significa ter coragem para fazer algo questionável ou desrespeitoso.
  - Exemplo: "Ele teve a cara de pau de pedir dinheiro emprestado novamente."
- De mal a pior: indica uma situação que está se deteriorando ou piorando.
  - Exemplo: "A situação financeira da empresa está de mal a pior."

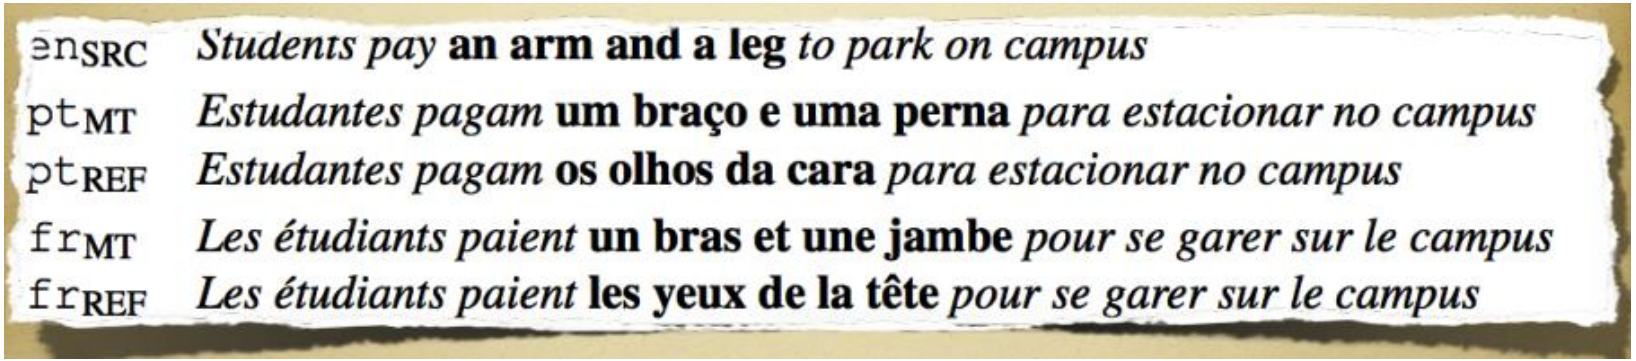
MWE - Exemplos

- Pôr do sol: momento em que o sol se põe no horizonte.
  - Exemplo: "Vamos assistir ao pôr do sol na praia."
- Mão na roda: algo ou alguém que facilita uma tarefa ou situação.
  - Exemplo: "Ter um carro próprio é uma mão na roda para quem precisa se deslocar."
- Cara a cara: frente a frente, em uma situação direta de confronto ou encontro.
  - Exemplo: "Precisamos resolver essa questão cara a cara."
- De mal a bem: indica uma situação que estava ruim, mas melhorou.
  - Exemplo: "Depois de conversarmos, resolvemos nossas diferenças de mal a bem."
- Pé na jaca: expressão utilizada para indicar excessos, principalmente relacionados à comida ou bebida.
  - Exemplo: "Hoje eu vou sair e colocar o pé na jaca na festa."

MWE - Problemas



en_{SRC}	*I* **paid** *my poor parents* **a visit**
pt_{MT}	*Eu* **pago** *os meus pais pobres* **uma visita**
pt_{REF}	*Eu* **fiz uma visita** *aos meus pobres pais*
fr_{MT}	*J'ai* **payé** *mes pauvres parents* **une visite**
fr_{REF}	*J'ai* **rendu visite** *à mes pauvres parents*



en_{SRC}	*Students pay* **an arm and a leg** *to park on campus*
pt_{MT}	*Estudantes pagam* **um braço e uma perna** *para estacionar no campus*
pt_{REF}	*Estudantes pagam* **os olhos da cara** *para estacionar no campus*
fr_{MT}	*Les étudiants paient* **un bras et une jambe** *pour se garer sur le campus*
fr_{REF}	*Les étudiants paient* **les yeux de la tête** *pour se garer sur le campus*